

Cadeias de Markov

?!

- O que esteve na origem do grande sucesso inicial da Google ?
- O que tem em comum esse sucesso com a capacidade de interagir por voz com computadores, robôs e smartphones ?
 - No reconhecimento de fala ?
 - Na síntese de fala ?

Exemplo 1

- Suponhamos que em cada dia que têm aulas de MPEI acordam e decidem se vêm ou não à aula.
- Se vieram à aula anterior, a probabilidade de virem é 70%;
- se faltaram à anterior, essa probabilidade é 80%
- Algumas questões:
 - Se vieram à aula esta segunda, qual a probabilidade de virem na aula de **SEGUNDA** da próxima semana ?
 - Assumindo que o semestre tem duração infinita (que horror!), qual a percentagem aproximada de aulas a que estariam presentes ?

Exemplo 2

- Dividir a turma em 3 grupos A, B e C no início do semestre
- No final de cada aula:
- $\frac{1}{3}$ do grupo A vai para o B e outro $\frac{1}{3}$ do grupo A vai para o grupo C
- $\frac{1}{4}$ do grupo B vai para A e $\frac{1}{4}$ de B vai para C
- $\frac{1}{2}$ do grupo C vai para o grupo B
- Como ficarão os grupos ao fim de n aulas ?


Exemplo 3 – “Pub Crawl”

- Bares junto a uma conhecida Universidade:



Outro exemplo

- Passeio aleatório (random walk)



Cara Coroa Coroa ... Cara ...

Muitas áreas de aplicação

- Muitas vezes estamos interessados na transição de algo entre certos estados.
- Exemplos:
 - Movimento de pessoas entre regiões
 - Estado do tempo
 - Movimento entre as posições num jogo de Monopólio
 - Pontuação ao longo de um jogo
 - Estado de Filas de atendimento


Princípios básicos

Processos estocásticos

- Estendem o conceito de variável aleatória
- Lidam com a dinâmica da teoria de probabilidades
- Uma v.a. X mapeia um acontecimento $s \in \Omega$ num número $X(s)$
- O processo mapeia o evento para números diferentes em tempos diferentes
 - O que implica que em lugar de termos um número $X(s)$ temos $X(t, s)$
 - Sendo $t \in T$ geralmente um conjunto de tempos

Processos estocásticos

- 3 realizações de um processo estocástico






- Se fixarmos s , $X(t)$ é uma função real do tempo
- $X(t, s)$ pode então ser vista como uma **colecção de funções no tempo**
- Se fixarmos t temos uma função $X(s)$ que depende apenas de s , ou seja uma variável aleatória
- Um nome alternativo é processos aleatórios

Classificação de processos estocásticos

- Podem ser classificados segundo t e os valores que pode assumir (estados do processo)
- Quanto ao tempo :
 - Tempo contínuo: Se tempo é um intervalo contínuo
 - Tempo discreto: Se o tempo é um conjunto contável
 - Também chamada sequência aleatória e representada por $X[n]$
- Quanto ao conjunto de estados (E):
 - Contínuo
 - Discreto

Estados



Definição

- Um **processo de Markov** é um **processo estocástico** em que a probabilidade de o sistema **estar num estado** específico num determinado período de observação **depende apenas do seu estado** no período de observação imediatamente **precedente**
 - O futuro apenas depende do presente e não do passado

Tipos de processos de Markov

- Discretas/contínuas

		Espaço de estados	
		Discreto	Contínuo
Tempo	Discreto	Cadeia de Markov tempo discreto	Processo de Markov em tempo discreto
	Contínuo	Cadeia de Markov tempo contínuo	Processo de Markov em tempo contínuo

- Focaremos a nossa atenção em **cadeias de Markov de tempo discreto**

Cadeias de Markov discretas

- X_n : estado após n transições
 - Pertence a um conjunto finito,
 - Em geral $\{1, 2, \dots, m\}$
 - X_0 é dado ou aleatório

Questões comuns relativas a cadeias de Markov

- Qual a probabilidade de transição entre dois estados em n observações ?
- Existe algum equilíbrio ?
- Existe uma estabilidade a longo prazo ?

Propriedade de Markov

- Probabilidade de transição do estado i para o estado j :
- $p_{ji} = P(X_{n+1} = j | X_n = i, X_{n-1} = x_{n-1}, \dots, X_0 = x_0)$
 $= P(X_{n+1} = j | X_n = i)$
- Quando estas probabilidades p_{ji} não dependem de n a cadeia diz-se homogénea
 - Focaremos a nossa atenção neste tipo de cadeias de Markov


Propriedade de Markov

- $P(X_0 = x_0, X_1 = x_1, X_2 = x_2 \dots) = ?$

$$= P(X_0 = x_0) P(X_1 = x_1 | X_0 = x_0) P(X_2 = x_2 | X_0 = x_0, X_1 = x_1) \dots$$

$$= P(X_0 = x_0) P(X_1 = x_1 | X_0 = x_0) P(\textcolor{blue}{X}_2 = \textcolor{blue}{x}_2 | \textcolor{blue}{X}_1 = \textcolor{blue}{x}_1) \dots$$

- O processo “não tem memória”



Especificação de uma cadeia

- Identificar os **estados** possíveis
- Identificar as **transições** possíveis
- Identificar as **probabilidades de transição**

Aplicando ao exemplo 1 – faltar ou não faltar à aula

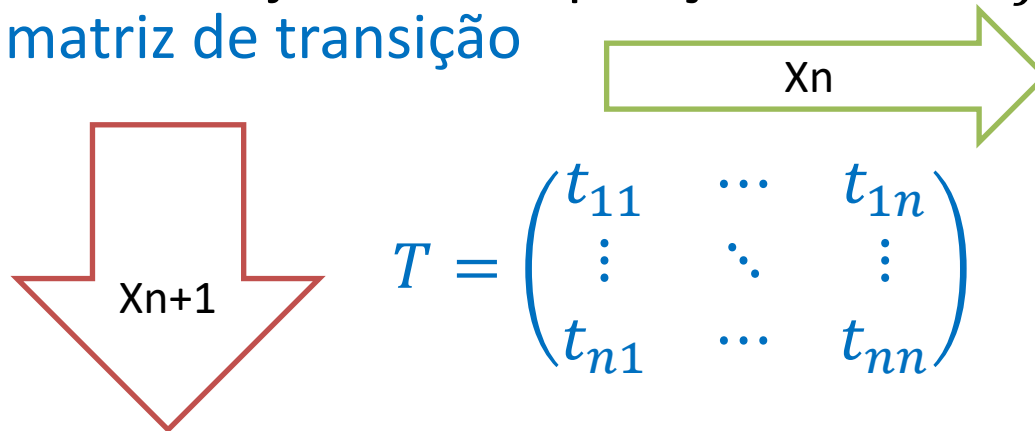
- Estados ?
- Transições ?
- Probabilidades de transição ?

Aplicando ao exemplo 1 – faltar ou não faltar à aula

- Estados ?
 - 2: {faltar, não faltar}
- Transições ?
 - Faltar-> não faltar : 0,8
 - Não faltar -> faltar : 0,3
 - Faltar -> faltar : 0,2
 - Não faltar -> não faltar: 0,7
- Probabilidades de transição ?

Matriz de transição

- É usual representar as probabilidades de transição através de uma matriz, **chamada de matriz de transição**
- Tendo o sistema n estados possíveis, para cada par i, j fazemos t_{ji} igual à probabilidade de mudar **do estado i para o estado j** .
- A matriz T cujo valor na posição linha = j , coluna = i é t_{ji} é a **matriz de transição**


$$T = \begin{pmatrix} t_{11} & \cdots & t_{1n} \\ \vdots & \ddots & \vdots \\ t_{n1} & \cdots & t_{nn} \end{pmatrix}$$

- Nota: Alguns autores adoptam t_{ij} como a probabilidade de mudar do estado i para o estado j

Matriz T do Exemplo 1


- $T = \begin{pmatrix} ? & ? \\ ? & ? \end{pmatrix}$
- Considerando estado 1 “não faltar”, temos
- $T = \begin{matrix} \text{não faltar} & \rightarrow & (0,7 & 0,8) \\ \text{faltar} & \rightarrow & (0,3 & 0,2) \end{matrix}$

Matriz T do Exemplo 2

$$T = \begin{matrix} & \begin{matrix} A & B & C \end{matrix} \\ \begin{matrix} A \\ B \\ C \end{matrix} & \begin{bmatrix} ? & ? & ? \\ ? & ? & ? \\ ? & ? & ? \end{bmatrix} \end{matrix}$$

Matriz T do Exemplo 2


$$T = \begin{array}{c|ccc} & A & B & C \\ \hline A & 1/3 & & \\ B & 1/3 & & \\ C & 1/3 & & \end{array}$$



Futuro Estado

Matriz T do Exemplo 2

$$T = \begin{array}{c|ccc} & A & B & C \\ \hline A & 1/3 & 1/4 & 0 \\ B & 1/3 & 1/2 & 1/2 \\ C & 1/3 & 1/4 & 1/2 \end{array}$$



Futuro Estado

Matriz T é estocástica


- A matriz de transição reflecte propriedades importantes das probabilidades:
 - Todas as entradas são não-negativas
 - Os valores em **cada COLUNA** somados dão sempre resultado 1
- Devido a estas propriedades a matriz é denominada de **matriz estocástica**

Representação gráfica da cadeia

- Adequada e possível para número de estados pequeno
- **Nós**: representam todos os estados
- **Setas**: para todas as transições permitidas (one-step)
 - Ou seja, seta entre i e j apenas de $p_{ji} > 0$

Representação gráfica da cadeia

- Exemplo:



Simulação / Visualização dinâmica

- Estão disponíveis online formas de visualizar as transições entre estados ao longo do tempo ...
- Um desses exemplos é **Markov Chains - A visual explanation by [Victor Powell](#)**

- <http://setosa.io/blog/2014/07/26/markov-chains/index.html>

Que inclui:

- <http://setosa.io/markov/index.html#%7B%22tm%22%3A%5B%5B0.5%2C0.5%5D%2C%5B0.5%2C0.5%5D%5D%7D>

- Para usar precisamos apenas de introduzir a matriz T
 - Que define o número de estados, quais as transições possíveis e as probabilidades associadas a essas transições

Simulando os nossos exemplos

- Exemplo 1:
 - Matriz:
[[0.7, 0.3],
[0.8, 0.2]]
 - <http://setosa.io/markov/index.html#%7B%22tm%22%3A%5B%5B0.7%2C0.3%5D%2C%5B0.8%2C0.2%5D%5D%7D>
- Exemplo 2:
 - Matriz:
[[0.33,0.33,0.34],
[0.25,0.5,0.25],
[0,0.5,0.5]]
- Outro exemplo
 - [[0,1,0,0],
[0,0,1,0],
[0,0,0,1],
[0.2,0.3,0.3,0.2]]
 - O que vamos ver ?
 - Acesso directo:
<http://setosa.io/markov/index.html#%7B%22tm%22%3A%5B%5B0%2C1%2C0%2C0%5D%2C%5B0%2C0%2C1%2C0%5D%2C%5B0%2C0%2C0%2C1%5D%2C%5B0.2%2C0.3%2C0.3%2C0.2%5D%5D%7D>

Estado da cadeia num determinado instante

- O **estado** de uma cadeia de Markov com n estados no tempo (time step) k é dado pelo **vector estado**

$$\mathbf{x}^{(k)} = \begin{pmatrix} p_1^{(k)} \\ p_2^{(k)} \\ \vdots \\ p_n^{(k)} \end{pmatrix}$$

- Onde $p_j^{(k)}$ é a probabilidade de o sistema estar no estado j no instante de tempo k

Vector estado/probabilidade

- Considerando o exemplo 1:
- Suponhamos que após 10 aulas a probabilidade de faltar e não faltar são iguais
- Então o vector representativo do estado (state vector) seria:

$$\mathbf{x}^{(10)} = \begin{pmatrix} 0,5 \\ 0,5 \end{pmatrix}$$

- Este vector também se designa por **vector de probabilidade**
 - Todos elementos não-negativos
 - Soma dos elementos igual a um

Exemplo 2

- Supondo que começávamos com 20 estudantes no grupo A e 10 estudantes nos outros dois grupos, o vector relativo ao estado inicial seria

- $\mathbf{x}^{(0)} = \begin{pmatrix} 0,5 \\ 0,25 \\ 0,25 \end{pmatrix}$

Vector estado após uma transição

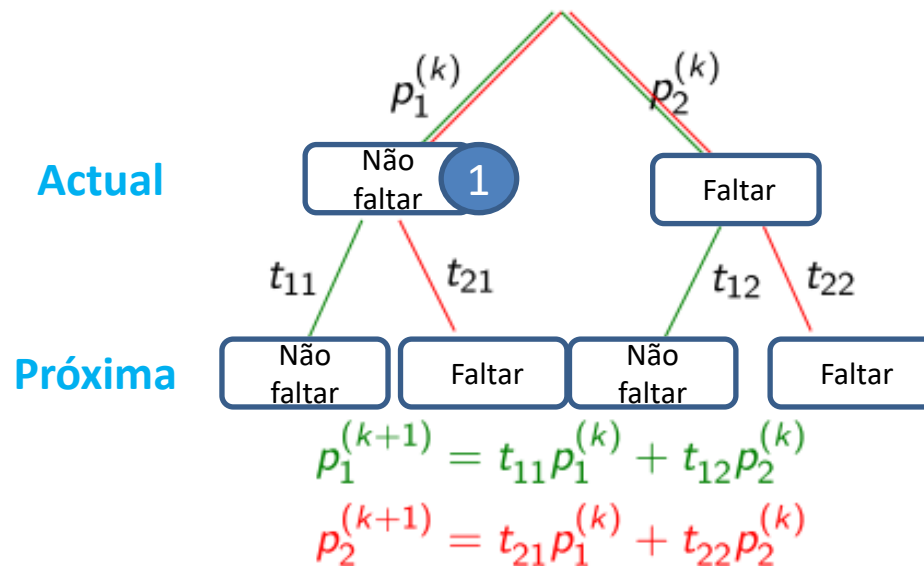
- Como obter $\mathbf{x}^{(k+1)}$?
- O vector de estado $\mathbf{x}^{(k+1)}$ no período de observação $k + 1$ pode ser determinado a partir do vector $\mathbf{x}^{(k)}$ através de:

$$\mathbf{x}^{(k+1)} = T\mathbf{x}^{(k)}$$

- Que resulta da probabilidade condicional:
- $P(\text{estado } j \text{ em } t = k + 1)$
- $= \sum_{i=1}^n P(\text{transição do estado } i \text{ para o } j)P(\text{estado } i \text{ em } t = k)$

Exemplo de aplicação – Exemplo 1

- De que forma depende a probabilidade de ir à aula seguinte da probabilidade de estar na aula actual ?



Estado após múltiplas transições


- Ataquemos agora problemas do “tipo”:
 - Qual a **probabilidade de transição entre dois estados em n observações/transições ?**
- Exemplo 1:
 - Qual a **probabilidade dos que estiveram na aula de uma segunda virem à aula na segunda seguinte**
 - Assumindo as probabilidades do nosso exemplo !
 - Tendo em conta que temos aulas segunda e quarta (TP1).

Equações de Chapman-Kolmogorov

- Definindo a transição em n passos p_{ji}^n como a probabilidade de **um processo no estado i se encontrar no estado j após n transições** adicionais. Ou seja:
- $p_{ji}^n = P(X_{n+k} = j | X_k = i), \quad n \geq 0, i, j \geq 0$
- Obviamente $p_{ji}^1 = p_{ji}$
- As **equações de Chapman-Kolmogorov** permitem calcular estas probabilidades

$$p_{ji}^{n+m} = \sum_k p_{ki}^n p_{jk}^m \quad \forall n, m \geq 0, \forall i, j$$

Interpretação



Interpretação

- É fácil de compreender se tivermos em conta que $p_{ki}^n p_{jk}^m$ representa a probabilidade de:
 - Começando em i o processo ir para o estado j em $n + m$ transições..
 - Através de um caminho que o leva ao estado k na transição n
- Logo, somando para todos os estados intermédios k obtém-se a probabilidade de estar no estado j ao fim de $n + m$ transições

“Demonstração” Eqs. Chapman-Kolmogorov

- $p_{ji}^{n+m} = P(X_{n+m} = j | X_0 = i)$
- $= \sum_k P(X_{n+m} = j, X_n = k | X_0 = i)$
- $= \sum_k P(X_{n+m} = j | X_n = k) P(X_n = k | X_0 = i)$
- $\sum_k p_{jk}^m p_{ki}^n$

Em termos de matrizes

- Se usarmos $\mathbf{T}^{(n)}$ para representar a matriz com as probabilidades de n transições, a equação anterior transforma-se em:


$$\mathbf{T}^{(n+m)} = \mathbf{T}^{(n)} . \mathbf{T}^{(m)}$$

Em que o “.” significa multiplicação de matrizes

- Desta equação obtém-se facilmente:

$$\mathbf{T}^{(2)} = \mathbf{T}^{(1+1)} = \mathbf{T} . \mathbf{T} = \mathbf{T}^2$$

- E por indução $\mathbf{T}^{(n)} = \mathbf{T}^{(n-1+1)} = \mathbf{T}^{n-1} . \mathbf{T} = \mathbf{T}^n$
 - Ou seja, a matriz de transição relativa a n transições pode ser obtida multiplicando \mathbf{T} por si própria n vezes



Aplicação ao Exemplo 1

- Voltando a uma questão colocada no início da aula ...
- *Se vieram à aula esta segunda, qual a probabilidade de virem na aula de **SEGUNDA** da próxima semana ?*
- Solução:
- Temos $\mathbf{x}^{(0)} = \begin{pmatrix} 1 \\ 0 \end{pmatrix}$, significando “não faltar”
- Pretendemos $\mathbf{x}^{(2)}$, 0= hoje

...

- $\mathbf{x}^{(2)} = T\mathbf{x}^{(1)} = T(T\mathbf{x}^{(0)}) = T^2\mathbf{x}^{(0)}$

$$= \begin{pmatrix} 0.7 & 0.8 \\ 0.3 & 0.2 \end{pmatrix}^2 \begin{pmatrix} 1 \\ 0 \end{pmatrix} = \begin{pmatrix} 0.7 & 0.8 \\ 0.3 & 0.2 \end{pmatrix} \begin{pmatrix} 0.7 \\ 0.3 \end{pmatrix} = \begin{pmatrix} 0.73 \\ 0.27 \end{pmatrix}$$

- Ou seja probabilidade igual a 0.73 de virem na próxima Segunda

Terminologia



Tipos de estados

Tipos de matrizes de transição

...


Acessibilidade de um estado

- Possibilidade de ir do estado i para o estado j (existe caminho na cadeia de i para j).



Estados comunicantes

- Dois estados comunicam se ambos são acessíveis a partir do outro.




- Um sistema é não redutível (irreducible) se todos os estados comunicam
- Classe:** conjunto de estados que comunicam entre si

Estado recorrente

- Um estado s_i é um **estado recorrente** se o sistema puder sempre voltar a ele (depois de sair dele).
- De uma forma mais formal: s_i é um **estado recorrente** se, para todos os estados s_j , a existência de um inteiro r_j tal que $p_{ji}^{(r_j)} > 0$ implica que existe um inteiro r_i tal que $p_{ij}^{(r_i)} > 0$
- Um estado não recorrente é transiente

Estados recorrentes ?



- Os 3 estados são recorrentes


Estado transiente

- Um estado é transiente se **existe um outro estado qualquer para o qual o** processo de Markov **pode transitar, mas do qual o processo não pode retornar**
- Ou seja, se existe um estado s_j e um inteiro l tal que $p_{ji}^{(l)} \neq 0$ e $p_{ij}^{(r)} = 0$ para $r = 0, 1, 2, \dots$
- A probabilidade destes estados tende para zero quando n tende para infinito
 - Pois apenas são visitados um número finito de vezes


Estado periódico

- Um estado é **periódico** se apenas se pode regressar a ele após um número fixo de transições superior a 1 (ou múltiplos desse número).
- Formalizando:
 - Um estado recorrente s_i diz-se **periódico** se existe um inteiro $c > 1$ tal que $p_{ii}^{(r)}$ é igual a zero para todos os valores de r excepto $r = c, 2c, 3c, \dots$

Estado periódico



Todos estados visitados em múltiplos de 3 iterações




Todos estados visitados em múltiplos de 3 iterações

- Um estado não periódico é **aperiódico**
 - Como era de esperar!

Estado absorvente

- Um estado **absorvente** é um **estado do qual não é possível sair** (ou seja transitar para outro estado)
- Uma cadeia é absorvente se tiver pelo menos um estado absorvente




- Os estados 0 e 4 são absorventes

Aplicação dos conceitos

- Exemplo:

State	0	1	2	3
0	0	X	X	0
1	X	0	0	0
2	0	0	0	X
3	X	0	0	X



- Todos os pares de estados comunicam, formando um única classe recorrente
 - Os estados são aperiódicos
- Em consequência o processo é aperiódico e irreduzível

Assuntos principais dados anteriormente

- Noção de processo estocástico
- Cadeias de Markov
- Propriedade de Markov
- Matriz de transição T
- Representação gráfica
- $\mathbf{T}^{(n)}$

Demos

- **Wolfram:**
 - **Finite-State, Discrete-Time Markov Chains**
 - <http://demonstrations.wolfram.com/ATwoStateDiscreteTimeMarkovChain/>
 - <http://demonstrations.wolfram.com/FiniteStateDiscreteTimeMarkovChains/>

O que acontece ao fim de muitas
transições ?

Potências de T quando $n \rightarrow \infty$

- Exemplo 2 (3 grupos de alunos):
- Vejamos o comportamento de T^n ao aumentar n ...

$$T = \begin{pmatrix} 0.333333 & 0.25 & 0. \\ 0.333333 & 0.5 & 0.5 \\ 0.333333 & 0.25 & 0.5 \end{pmatrix}$$

$$T^2 = \begin{pmatrix} 0.194444 & 0.208333 & 0.125 \\ 0.444444 & 0.458333 & 0.5 \\ 0.361111 & 0.333333 & 0.375 \end{pmatrix}$$

$$T^3 = \begin{pmatrix} 0.175926 & 0.184028 & 0.166667 \\ 0.467593 & 0.465278 & 0.479167 \\ 0.356481 & 0.350694 & 0.354167 \end{pmatrix}$$

$$T^4 = \begin{pmatrix} 0.17554 & 0.177662 & 0.175347 \\ 0.470679 & 0.469329 & 0.472222 \\ 0.353781 & 0.353009 & 0.352431 \end{pmatrix}$$

$$T^5 = \begin{pmatrix} 0.176183 & 0.176553 & 0.176505 \\ 0.470743 & 0.47039 & 0.470775 \\ 0.353074 & 0.353057 & 0.35272 \end{pmatrix}$$

$$T^6 = \begin{pmatrix} 0.176414 & 0.176448 & 0.176529 \\ 0.470636 & 0.470575 & 0.470583 \\ 0.35295 & 0.352977 & 0.352889 \end{pmatrix}$$

Continuando... (em Matlab)

% n =10

Tn =

0.1765 0.1765 0.1765

0.4706 0.4706 0.4706

0.3529 0.3529 0.3529


% n=100

Tn =

0.1765 0.1765 0.1765


0.4706 0.4706 0.4706

0.3529 0.3529 0.3529



Exemplo 1 (faltar/não faltar)

```
T=[0.7 0.8  
    0.3 0.2]  
Tn= T;  
pij= Tn(:);  
for n=2:10  
    Tn= T*Tn;  
    pij=[ pij Tn(:)];  
    plot(pij')  
    drawnow  
end  
Tn
```



Tn =

0.7273	0.7273
0.2727	0.2727

Questões ?

- Converge ?
- Para quê ?

Equilíbrio

- As cadeias dos nossos exemplos atingem um equilíbrio.
- Quando isso acontece a probabilidade de qualquer estado torna-se constante independentemente do passo (step) e das condições iniciais
- Para analisar essa situação é necessário considerar um certo tipo de cadeias de Markov...

Matriz/ Processo regular

- A matriz de transição (ou o processo de Markov correspondente) é **regular** se alguma potência da matriz tem todos os valores não-nulos.
 - Existe uma **probabilidade de mudar de qualquer estado para qualquer estado**
- Qualquer matriz de transição sem elementos nulos é uma matriz regular.
- No entanto, uma matriz contendo elementos nulos pode ser regular.
 - Por exemplo: $T = \begin{bmatrix} 0 & 0 & 0.5 \\ 1 & 0 & 0.5 \\ 0 & 1 & 0 \end{bmatrix}$

...

- No caso de matrizes com elementos nulos, pode verificar-se se é regular substituindo os elementos não-nulos por “X” e calculando potências sucessivas
- No nosso exemplo:

$$\bullet \quad T = \begin{bmatrix} 0 & X & 0 \\ 0 & 0 & X \\ X & X & 0 \end{bmatrix}, T^2 = \begin{bmatrix} 0 & 0 & X \\ X & X & 0 \\ 0 & X & X \end{bmatrix} \dots, T^8 = \begin{bmatrix} X & X & X \\ X & X & X \\ X & X & X \end{bmatrix}$$

Cadeia **ergódica**

- Uma cadeia de Markov diz-se ergódica se é possível efectuar transições de qualquer estado para qualquer outro estado
- Em consequência, uma **cadeia regular é também ergódica**

Cadeia ergódica

- No entanto, **nem todas as cadeias ergódicas são regulares**
 - Exemplo: se de um determinado estado se pode transitar para alguns estados apenas num número par de transições e para outros num número ímpar de transições, então todas as potências da matriz de transição terão elementos nulos

$$T = \begin{bmatrix} 0 & 0.5 & 0 \\ 1 & 0 & 1 \\ 0 & 0.5 & 0 \end{bmatrix}$$

...

- Potências pares

```
>> T^30
```

```
ans =
```

```
0.5000    0    0.5000
    0 1.0000    0
0.5000    0    0.5000
```

```
>> T^100
```

```
ans =
```

```
0.5000    0    0.5000
    0 1.0000    0
0.5000    0    0.5000
```

- Potências ímpares

```
>> T^5
```

```
ans =
```

```
    0 0.5000    0
1.0000    0 1.0000
    0 0.5000    0
```

```
>> T^51
```

```
ans =
```

```
    0 0.5000    0
1.0000    0 1.0000
    0 0.5000    0
```

$$\lim_{n \rightarrow \infty} T^n$$

- Se T é a matriz de transição de um processo de Markov **regular** então:
- $\lim_{n \rightarrow \infty} T^n$ é a matriz:

$$A = \begin{bmatrix} u_1 & u_1 & \cdots & u_1 \\ u_2 & u_2 & \cdots & u_2 \\ \cdots & \cdots & \cdots & \cdots \\ u_N & u_N & \cdots & u_N \end{bmatrix}$$

Com todas as colunas idênticas

- Cada coluna \mathbf{u} é um vector probabilidade em que todas as componentes são positivas

Vector estado estacionário (steady-state vector)

- Sendo T uma matriz de transição regular e \mathbf{u} o resultado de $\lim_{n \rightarrow \infty} T^n$ (slide anterior), demonstra-se que:

- a) Para qualquer vector de probabilidade \mathbf{x} , $T^n \mathbf{x} \rightarrow \mathbf{u}$ quando $n \rightarrow \infty$

Sendo \mathbf{u} o vector estado estacionário (**steady-state vector**)

- b) \mathbf{u} é o único vector de probabilidade que satisfaz a equação matricial $\mathbf{T}\mathbf{u} = \mathbf{u}$
- c) $\lim_{n \rightarrow \infty} \left(\frac{\eta(i,n)}{n} \right) = \mathbf{u}(i)$, em que $\eta(i,n)$ é o número de visitas ao estado i em n passos (transições)

Cálculo do vector estado estacionário

- Sabemos que o vector correspondente ao estado estacionário é único.
- Usamos a equação que ele satisfaz para o calcular: $\mathbf{T}\mathbf{u} = \mathbf{u}$
- Ou, na forma matricial, $(\mathbf{T} - \mathbf{I})\mathbf{u} = 0$

Exemplo 1 (aulas)

- $\mathbf{T}\mathbf{u} = \mathbf{u}$

- $\begin{bmatrix} 0,7 & 0,8 \\ 0,3 & 0,2 \end{bmatrix} \begin{bmatrix} u_1 \\ u_2 \end{bmatrix} = \begin{bmatrix} u_1 \\ u_2 \end{bmatrix}$

- $$\begin{cases} \frac{7}{10}u_1 + \frac{8}{10}u_2 = u_1 \\ \frac{3}{10}u_1 + \frac{2}{10}u_2 = u_2 \end{cases} = \begin{cases} \frac{-3}{10}u_1 + \frac{8}{10}u_2 = 0 \\ \frac{3}{10}u_1 + \frac{-8}{10}u_2 = 0 \end{cases}$$
$$\begin{matrix} u_1 + u_2 = 1 \end{matrix}$$

- ...

Em Matlab

Uma possível solução:

% matriz de transição

$T = [7 \ 8; 3 \ 2]/10$

% $(T-I)u$ aumentado com u_1+u_2

$M = [T - \text{eye}(2);$
 $\text{ones}(1,2)]$

%

$x = [0 \ 0 \ 1]'$

% resolver para obter u

$u = M \backslash x$

Resultado:

0.7273

0.2727

Ou seja aprox. 72 % de
probabilidade de não
faltarem



Exemplo1.m

Outra possibilidade

% matriz de transição

T=[7 8; 3 2]/10;

% resolver equação $Au = b$

aux= (T-eye(length(T)));

% usas as primeiras linhas de T + equação $x_1+x_2= 1$

A= [aux(1:end-1,:); 1 1];

b= [0 1]';

u= inv(A)*b

...

- Pode também ser resolvido usando uma matriz aumentada e a função **rref()**

`%Matlab`

`C= [M x]`

`rref(C)`

$$\left(\begin{array}{cc|c} -3/10 & 8/10 & 0 \\ 3/10 & -8/10 & 0 \\ 1 & 1 & 1 \end{array} \right) \rightsquigarrow \left(\begin{array}{cc|c} 1 & 0 & 8/11 \\ 0 & 1 & 3/11 \\ 0 & 0 & 0 \end{array} \right)$$

- Mais informação:
<https://www.math.ucdavis.edu/~daddel/MATH22AL/LABS/LAB2/lab2.pdf>

Exemplo 2


- Aplicando a última técnica ao nosso exemplo 2 (grupos) teremos

$$\left(\begin{array}{ccc|c} -2/3 & 1/4 & 0 & 0 \\ 1/3 & -1/2 & 1/2 & 0 \\ 1/3 & 1/4 & -1/2 & 0 \\ 1 & 1 & 1 & 1 \end{array} \right) \rightsquigarrow \left(\begin{array}{ccc|c} 1 & 0 & 0 & 3/17 \\ 0 & 1 & 0 & 8/17 \\ 0 & 0 & 1 & 6/17 \\ 0 & 0 & 0 & 0 \end{array} \right)$$

Cadeias com estados absorventes

Estados absorventes

- Um **estado absorvente** é um estado do qual não é possível sair (ou seja transitar para outro estado)



- Os estados 0 e 4 são absorventes


Cadeias absorventes

- Uma **cadeia** é **absorvente** se:

(1) tiver pelo menos um estado absorvente

(2) é possível ir de cada um dos estados não absorventes para pelo menos um dos estados absorventes num número finito de passos.

Exemplo simples



Demo

- Absorbing Markov Chain
 - <http://demonstrations.wolfram.com/AbsorbingMarkovChain/>

Forma canónica da matriz de transição

Forma canónica

- Se numa matriz de transição **agruparmos todos os estados absorventes** obtemos a denominada forma canónica (standard form)
- O mais usual é colocar **primeiro os não absorventes** e depois os absorventes.
- **A forma canónica** é muito útil para determinar as matrizes em situações limite de cadeias de Markov absorventes
 - Como veremos...

Forma canónica

- Rearranjar os estados da matriz T por forma a que os **estados transientes** apareçam **primeiro**

Matriz $t \times t$

$$\begin{array}{c} \text{TR.} \\ \text{ABS.} \end{array} \begin{pmatrix} \text{TR.} & \text{ABS.} \\ \hline Q & 0 \\ \hline R & I \end{pmatrix}$$

t : # estados transientes
 a : # estados absorventes


$a \times a$ matriz
identidade

Aplicação a um exemplo

- Homem a caminhar para casa de um bar
 - 4 quarteirões entre o bar e a casa
 - 5 estados no total
- Estados absorventes:
 - Esquina 4 – Casa
 - Esquina 0 – Bar
- No limite de cada quarteirão existe igual probabilidade de seguir em frente ou retroceder

Diagrama e matriz de transição

- Diagrama de transição




- Matriz de transição :

$$T = \begin{bmatrix} 1 & 1/2 & 0 & 0 & 0 \\ 0 & 0 & 1/2 & 0 & 0 \\ 0 & 1/2 & 0 & 1/2 & 0 \\ 0 & 0 & 1/2 & 0 & 0 \\ 0 & 0 & 0 & 1/2 & 1 \end{bmatrix}$$

Forma canónica

- $T = \begin{bmatrix} 1 & 1/2 & 0 & 0 & 0 \\ 0 & 0 & 1/2 & 0 & 0 \\ 0 & 1/2 & 0 & 1/2 & 0 \\ 0 & 0 & 1/2 & 0 & 0 \\ 0 & 0 & 0 & 1/2 & 1 \end{bmatrix}$



Q

$$T = \begin{array}{c} \begin{array}{c} \text{1} \quad \text{2} \quad \text{3} \end{array} \\ \left[\begin{array}{ccc|cc} 0 & 1/2 & 0 & 0 & 0 \\ 1/2 & 0 & 1/2 & 0 & 0 \\ 0 & 1/2 & 0 & 0 & 0 \\ \hline 1/2 & 0 & 0 & 1 & 0 \\ 0 & 0 & 1/2 & 0 & 1 \end{array} \right] \begin{array}{c} \text{0} \quad \text{4} \\ \text{0} \quad \text{1} \end{array} \end{array}$$

R
0
I

Diferentes notações

- *Na nossa notação a estrutura é:*

$$\begin{array}{cc} Q & 0 \\ R & I \end{array}$$

- *Na notação alternativa:*

$$\begin{array}{cc} Q & R \\ 0 & I \end{array}$$

Q

- A sub-matriz Q descreve probabilidades de transição de estados não-absorventes para estados não-absorventes

Situação limite

Situação limite

- Situações limite de cadeias de Markov absorventes ?
- Como é óbvio a cadeia irá acabar por ficar indefinidamente num dos estados absorventes !
- Mas mesmo assim existem questões relevantes:
- Qual o estado absorvente mais provável quando temos vários ?
- Dado um estado inicial, qual o número esperado de transições até ocorrer absorção ?
- Dado um estado inicial, qual a probabilidade de ser absorvido por um estado absorvente em particular ?

Potências de T

- Multiplicando repetidamente a matriz de transição na sua forma canónica vê-se que:
- $T^n = \begin{bmatrix} Q^n & 0 \\ X & I \end{bmatrix}$
- A expressão exacta de X não tem interesse, mas Q e Q^n são importantes

$$Q^n$$

- A matriz Q^n representa a probabilidade de permanecer em estados não-absorventes após n passos
 - Q^n tende para zero quando n aumenta
 - $Q^n \rightarrow 0$ quando $n \rightarrow \infty$

Matriz fundamental

- Multiplicando verifica-se que
- $(I - Q)(I + Q + Q^2 + \dots + Q^n) = I - Q^{n+1}$
- Fazendo $n \rightarrow \infty$ temos
- $(I - Q)(I + Q + Q^2 + \dots) = I$
- porque $Q^n \rightarrow 0$
- Isto mostra que
- $(I - Q)^{-1} = I + Q + Q^2 + Q^3 + \dots$

Matriz Fundamental

$$F = (I - Q)^{-1}$$

é a **matriz fundamental** do percurso aleatório

Interpretação de F

- Sejam $X_k(ji)$ as variáveis aleatórias definidas por:
- $$X_k(ji) = \begin{cases} 1, & \text{se estiver em } j \text{ após } k \text{ passos,} \\ & \text{partindo de } i \\ 0, & \text{caso contrário} \end{cases}$$
- A soma $X_0(ji) + X_1(ji) + \dots + X_n(ji)$ representa o número de visitas ao estado j , partindo do estado i , ao fim de n passos.
- O seu valor médio é dado por

$$E[X_0(ji) + X_1(ji) + \dots + X_n(ji)] = \sum_{k=0}^n E[X_k(ji)]$$

- Lembrar média de soma de variáveis !

Interpretação de F (continuação)

- Mas $E[X_k(ji)] = 1 \times p + 0 \times (1 - p)$ como em qualquer variável de Bernoulli
- E p designa a probabilidade de atingir o estado j após k passos, partindo de i
 - Ou seja exactamente o valor da coluna i e linha j de Q^k .
- Logo:

$$E[X_0(ji) + X_1(ji) + \cdots + X_n(ji)] = \sum_{k=0}^n Q^k(ji)$$

Interpretação de F (continuação)

- Os elementos de $I + Q + Q^2 + Q^3 + \dots + Q^n$ exprimem portanto o **número médio de visitas ao estado j partindo do estado i em n passos**
- Logo, **a matriz fundamental F** – que é o limite dessa quantidade quando $n \rightarrow \infty$ - **representa o número médio de visitas a cada estado antes da absorção**
- F_{ji} dá-nos o valor esperado para o número de vezes que um processo se encontra no estado s_j se começou no estado s_i
 - Antes de ser absorvido

Aplicando ao nosso exemplo

- $Q = \begin{bmatrix} 0 & 1/2 & 0 \\ 1/2 & 0 & 1/2 \\ 0 & 1/2 & 0 \end{bmatrix}$

- $I - Q = \begin{bmatrix} 1 & -1/2 & 0 \\ -1/2 & 1 & -1/2 \\ 0 & -1/2 & 1 \end{bmatrix}$

- $F = (I - Q)^{-1} = \begin{bmatrix} 3/2 & 1 & 1/2 \\ 1 & 2 & 1 \\ 1/2 & 1 & 3/2 \end{bmatrix}$



Exemplo2.m

Tempo médio até à absorção

- O **tempo médio até à absorção** será a **soma do número médio de visitas a todos os estados transientes até à absorção**
- Ou seja a **soma da coluna i de F**

$$t_i = \sum_j F_{ji}$$

- Na forma matricial pode obter-se o vector t usando

$$t = F' \mathbf{1}$$

- Em que :
 - $\mathbf{1}$ é uma vector coluna com uns

Tempo médio até absorção

- A soma da coluna i de F representa:
 - O valor esperado do **número de vezes que a cadeia passa por um qualquer estado transiente partindo do estado inicial** i antes da absorção
 - Valor esperado do tempo necessário até absorção partindo do estado i
- O vetor t contém os tempos médios até à absorção partindo dos vários estados transientes

Aplicando ao Exemplo: Tempo até absorção

- $t = F' \mathbf{1}$

$$= \begin{pmatrix} 3/2 & 1 & 1/2 \\ 1 & 2 & 1 \\ 1/2 & 1 & 3/2 \end{pmatrix} \begin{pmatrix} 1 \\ 1 \\ 1 \end{pmatrix}$$

$$= \begin{pmatrix} 3 \\ 4 \\ 3 \end{pmatrix} .$$



Exemplo2.m

Probabilidades de absorção

- As **probabilidades de absorção** b_{ji} no estado s_j se se iniciar no estado s_i podem ser obtidas através de:

$$B = R F$$

- Em que B é uma matriz $a \times t$ com entradas b_{ji}

Origem da expressão

- $B_{ji} = \sum_n \sum_k r_{jk} q^{(n)}_{ki}$
 - De i para k (transientes) e de k para j (absorvente)
 - Lembra-se de Chapman-Kolmogorov ?
- Trocando a ordem dos somatórios:
- $B_{ji} = \sum_k \sum_n r_{jk} q^{(n)}_{ki}$
- Usando definição da matriz fundamental:
- $B_{ji} = \sum_k r_{jk} F_{ki}$
- De onde se obtém
- $B_{ji} = (R F)_{ji}$

Aplicação ao nosso exemplo

- Relembremos que temos:


$$T = \begin{bmatrix} 0 & 1/2 & 0 & 0 & 0 \\ 1/2 & 0 & 1/2 & 0 & 0 \\ 0 & 1/2 & 0 & 0 & 0 \\ 1/2 & 0 & 0 & 1 & 0 \\ 0 & 0 & 1/2 & 0 & 1 \end{bmatrix} \text{ e } F = \begin{bmatrix} 3/2 & 1 & 1/2 \\ 1 & 2 & 1 \\ 1/2 & 1 & 3/2 \end{bmatrix}$$

- E portanto $R = \begin{bmatrix} 1/2 & 0 & 0 \\ 0 & 0 & 1/2 \end{bmatrix}$

- Multiplicando R e F obtemos $B = \begin{matrix} & \overset{1}{} & \overset{2}{} & \overset{3}{} \\ \overset{0}{} & 3/4 & 1/2 & 1/4 \\ \overset{4}{} & 1/4 & 1/2 & 3/4 \end{matrix}$

Aplicação a páginas web...

- Consideremos o conjunto de páginas web da figura:
- Qual o **número médio de visitas** às páginas 1,2 e 3 quando se parte da página 1?
- Quais os **tempos médios até absorção** ?



Número médio de visitas às páginas 1,2 e 3 quando se parte da página 1?

- São dados directamente pela matriz F
- Em Matlab ...

% OBTENHA T na forma canónica

% Obter Q

submatriz de 3x3

% calcular F



Exemplo3.m

Matlab

```
estados=[1 2 3 4];
```

```
% matriz T
```

```
Tcan=zeros(4);
```

```
Tcan(1,1)=0.8; Tcan(2,1)=0.2;
```

```
Tcan(2,2)=0.9; Tcan(3,2)=0.1;
```

```
Tcan(1,3)=0.3; Tcan(2,3)=0.2; Tcan(3,3)=0.4; Tcan(4,3)=0.1;
```

```
Tcan(4,4)=1;
```

```
%% Q
```

```
Q=Tcan(1:3,1:3)
```

```
%% F
```


```
aux= eye(size(Q)) - Q
```

```
F=inv(aux)
```

	F =		
20.0000	15.0000	15.0000	
60.0000	60.0000	50.0000	
10.0000	10.0000	10.0000	

Resposta à questão

- Os valores que nos interessam são os da coluna 1 (correspondentes a começar na página 1)
- Quando se parte da página 1, o número médio de visitas aos estados 1, 2 e 3 antes de ocorrer absorção será 20, 60 e 10, respectivamente
 - A página 2 receberá mais visitas
 - A página 3, com ligação directa ao estado absorvente terá muito menos visitas



Tempos médios até absorção ?

- Basta obter o vector t correspondente à soma das colunas de F

%Em Matlab...

```
t=F' * ones(3,1) % ou sum(F)
```

t =

90.0000

85.0000

75.0000



Exemplo3.m

Matriz B ?

- Neste exemplo não faz sentido pedir B pois só temos um estado absorvente
- Mas se fizermos $B = R F$ obtemos um vector de 1x3 só com uns
 - Confirmando o esperado